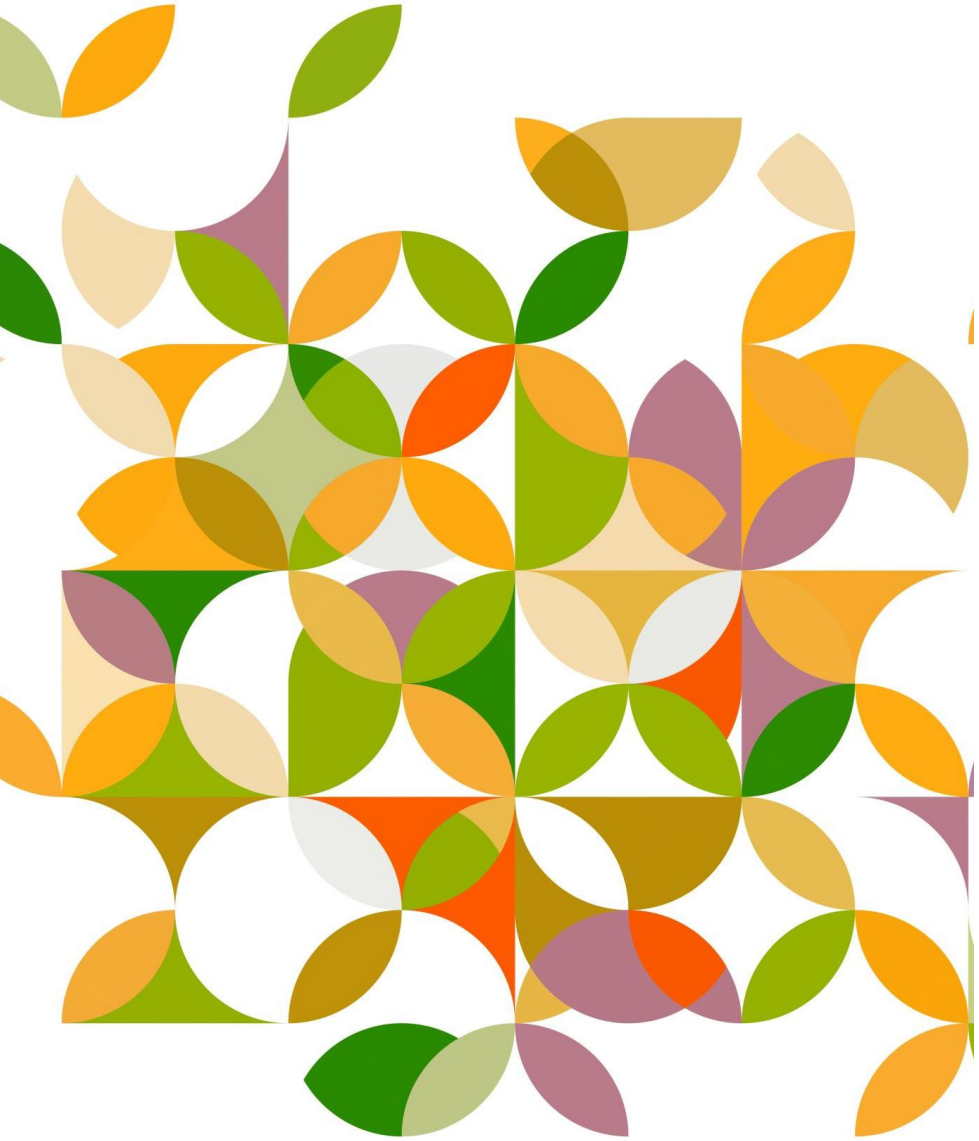

Machine Learning

EIN ÜBERBLICK

Definition und Ziel

Machine Learning (ML) ist ein Teilbereich der künstlichen Intelligenz (KI), der darauf abzielt, Computern die Fähigkeit zu verleihen, **aus Daten zu lernen und Vorhersagen oder Entscheidungen zu treffen**, ohne explizit programmiert zu sein.

Statt festgelegter Regeln werden Algorithmen genutzt, die **Muster in Daten erkennen und Modelle erstellen**, die diese Muster abbilden.

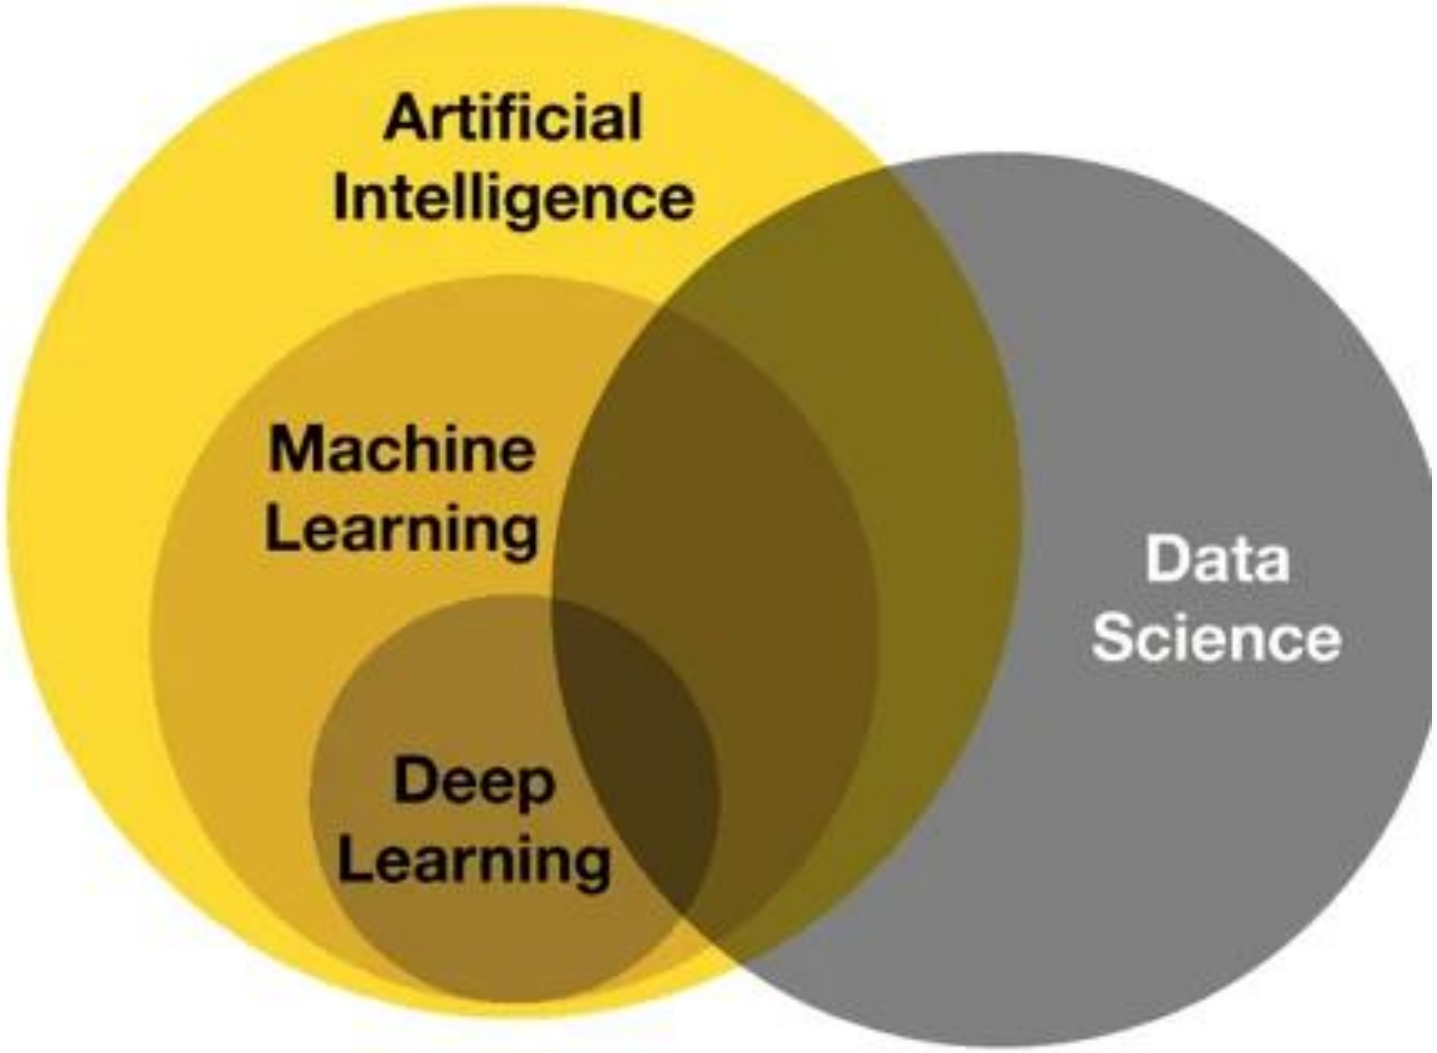

Quelle: https://www.deviq.io/insights/artificial-intelligence-vs-machine-learning-vs-data-science

Frühe Künstliche Intelligenz (teilweise immer noch aktuell, z.B. A*)

Spielgegner mit festen Regeln
z. B. Schach- oder Computerspiel-Gegner, die per If-Else-Logik, Zustandsautomaten oder **Minimax-Algorithmen** reagieren
→ kein Lernen, aber „intelligentes“ Verhalten

Expertensysteme
z. B. medizinische Diagnoseprogramme der 80er/90er
Wissen in Form von Regeln:
„Wenn Symptom A und B, dann Krankheit X“

Regelbasierte Chatbots
z. B. ELIZA
→ Mustererkennung + vordefinierte Antworten, kein Verständnis

Pfadfindung und Planung
z. B. A*-Algorithmus in Spielen oder Navigation
→ Zielgerichtetes Verhalten ohne Lernen

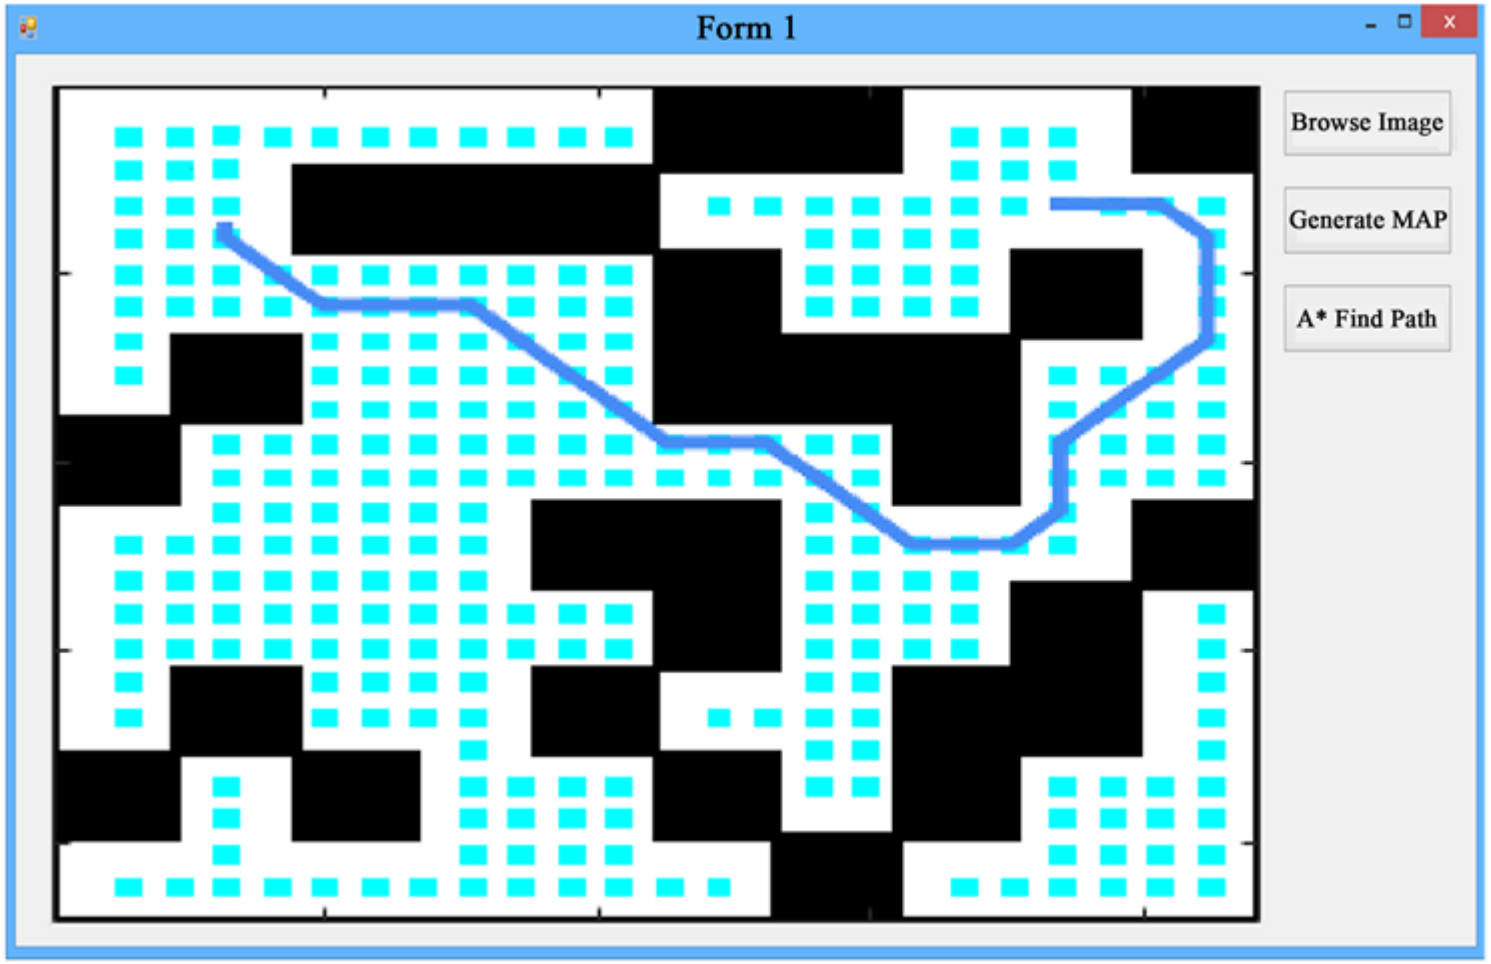

Quelle: https://www.scirp.org/journal/paperinformation?paperid=70460

Warum Machine Learning?

Traditionelle Programmierung basiert auf klar definierten Regeln. Machine Learning wird verwendet, wenn:

- Die Regeln zu komplex oder dynamisch sind, um manuell programmiert zu werden (z. B. Gesichtserkennung, Sprachübersetzung).

- Daten vorliegen, aus denen sich Modelle ableiten lassen.

- Flexibilität und Anpassungsfähigkeit an neue Daten erforderlich sind.

- Die ersten ML-Algorithmen stammen aus den 50er Jahren (reinforcement-learning (A. Samuel), neuronale Netze (F. Rosenblatt), k-nearest neighbours (Fix & Hodges), k-means (Stuart Lloyd / Mac Queen 1967) u.a.

Beispiele:

- Vorhersage von Aktienkursen oder Hauspreisen

- Personalisierte Produktempfehlungen in E-Commerce.

- Automatische Diagnose in der Medizin, z.B. Bilderkennungsverfahren (Brustkrebs, etc)

Arten des Machine Learnings

1. Überwachtes Lernen (Supervised Learning)
2. Unüberwachtes Lernen (Unsupervised Learning)
3. Verstärkendes Lernen (Reinforcement Learning)

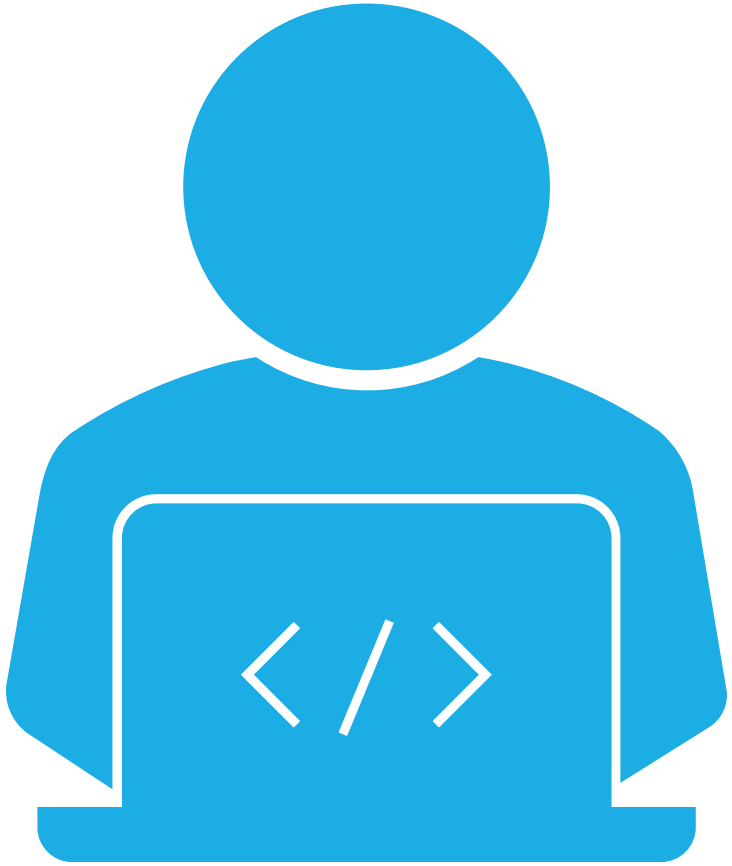

Überwachtes Lernen (Supervised Learning)

Das Modell wird mit gekennzeichneten Daten trainiert. Jede Eingabe ist mit einem bekannten Zielwert (Label) verknüpft. Ziel ist es, eine Funktion zu lernen, die Eingaben den richtigen Ausgaben zuordnet.

- **Anwendungsfälle:**

  - Klassifikation: Zu welcher Kategorie gehört eine Instanz (z. B. Spam-Erkennung)?

  - Regression: Vorhersage eines kontinuierlichen Werts (z. B. Preisprognose für Immobilien).

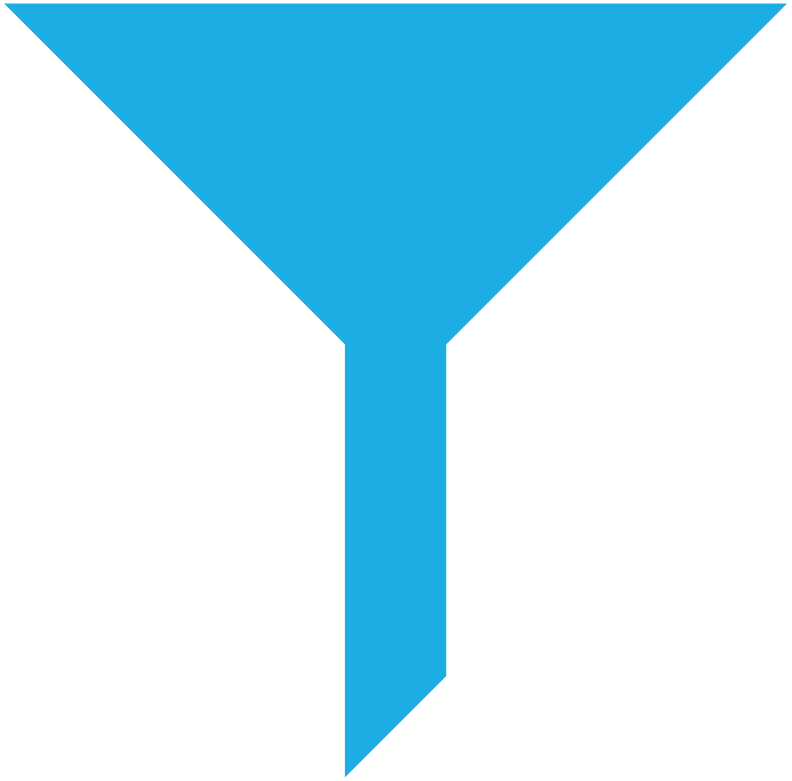

Unüberwachtes Lernen (Unsupervised Learning)

Es gibt keine gekennzeichneten Daten. Das Modell sucht Muster oder Strukturen in den Eingaben.

- **Anwendungsfälle:**

  - Clustering: Gruppierung ähnlicher Datenpunkte (z. B. Kundensegmentierung).

  - Dimensionsreduktion: Vereinfachung von Daten durch Reduzierung der Variablenanzahl (z. B. Principal Component Analysis).

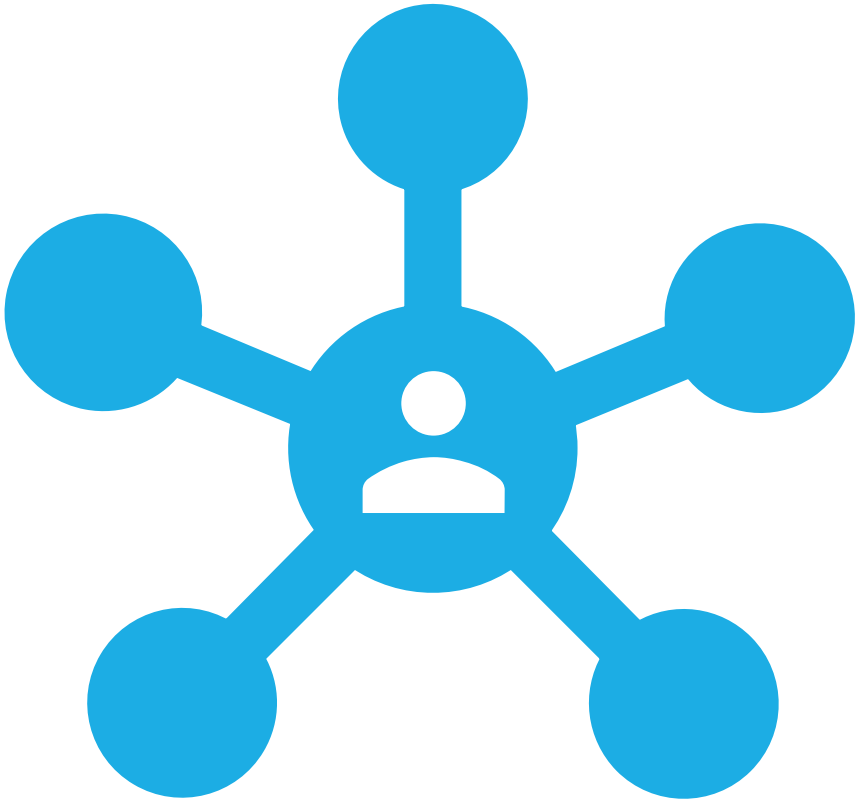

Verstärkendes Lernen (Reinforcement Learning)

Das Modell lernt durch Interaktionen mit einer Umgebung und erhält Belohnungen für gute Entscheidungen. Ziel ist es, Strategien zu entwickeln, die langfristige Belohnungen maximieren.

- **Anwendungsfälle:**
  - Spielsteuerung (z. B. Schach, Go).
  - Robotersteuerung, selbstfahrende Autos

Wichtige Algorithmen im überwachten Lernen

ÜBERWACHTES LERNEN

- **Lineare Regression:** Modelliert die Beziehung zwischen Eingaben und einem kontinuierlichen Zielwert.

- **Logistische Regression:** Für binäre Klassifikationsprobleme.

- **Entscheidungsbäume:** Baumstruktur zur Vorhersage von Kategorien oder Werten.

- **Random Forest:** Ensemble aus Entscheidungsbäumen zur Verbesserung der Genauigkeit.

- **Support Vector Machines (SVM):** Findet die Trennlinie mit maximalem Abstand zwischen Klassen.

Wichtige Algorithmen im unüberwachten Lernen

UNÜBERWACHTES LERNEN

- **k-Means Clustering:** Gruppiert Daten in k Cluster basierend auf Ähnlichkeit.

- **Hierarchisches Clustering:** Bildet eine hierarchische Struktur von Clustern.

- **Principal Component Analysis (PCA):** Reduziert die Dimensionen von Daten.

Wichtige Algorithmen im verstärkenden Lernen

Verstärkendes Lernen

- **Q-Learning:** Tabellarischer Ansatz zur Strategieoptimierung.

- **Deep Q-Networks:** Kombination von neuronalen Netzen und Reinforcement Learning.

Herausforderungen im Machine Learning

- **Datenqualität:** Schlechte oder verzerrte Daten führen zu ungenauen Modellen (Garbage IN, Garbage OUT)

- **Overfitting:** Das Modell passt zu gut an die Trainingsdaten an und generalisiert nicht gut auf neue Daten.

- **Underfitting:** Das Modell ist zu einfach, erfasst die zugrunde liegenden Muster der Trainingsdaten nicht und liefert sowohl auf Trainings- als auch auf neuen Daten schlechte Ergebnisse.

- **Rechenaufwand:** Große Datensätze und komplexe Algorithmen erfordern hohe Rechenleistung, häufig muss auf GPU zurückgegriffen werden.

- **Interpretierbarkeit:** Viele Modelle, insbesondere neuronale Netze, sind schwer zu interpretieren.

Tools und Frameworks in ML mit Python

Programmiersprachen

- **Python:** Häufigste Sprache im Machine Learning.

- **C, C++, Fortran, Rust:** unter der Haube nutzen numerische Bibliotheken schnelle Sprachen

Numerische Bibliotheken

- Numpy (Vektoren und Matritzen)
- Pandas (Tabellen)
- Matplotlib (Plotten), Seaborn (Plot-Erweiterung)

Frameworks

- **Scikit-learn:** Bibliothek für klassische ML-Algorithmen in Python.

- **TensorFlow und PyTorch:** Frameworks für Deep Learning.